

1. Методологические уязвимости и спорные допущения

1.1 Отсутствие дедубликации данных (Глава 2.1) В разделе предобработки не упоминается дедубликация. Корпус собран из Telegram-каналов, для которых характерны массовые репосты и кросс-постинг одних и тех же новостей. В контексте плотностной кластеризации (HDBSCAN) дубликаты искусственно завышают локальную плотность, создавая ложные микрокластеры и искажая веса c -TF-IDF. Если дедубликации не было, метрики кластеризации (особенно DBCV) могут быть искажены.

Мой комментарий: дедубликация не проводилась, действительно интересный момент, посты между каналами 100% будут семантически схожими на общие события, но тут могу подметить, что HDBSCAN в теории скорее всего такие документы будет объединять в сверхплотные кластеры и при оптимизации гиперпараметров эти структуры сливались в более крупные, но это мои домыслы

1.2 Валидность самописной метрики Gap (Формула 2.1) Метрика базируется на допущении: «документы одного канала семантически ближе друг к другу, чем документы разных каналов». Это крайне сильное и уязвимое допущение для новостного корпуса. Крупные новостные каналы публикуют посты на весь спектр тем (от погоды до геополитики). Внутри одного такого канала дисперсия тем будет огромной. Метрика имела бы смысл только в том случае, если все 67 каналов узкоспециализированные (один только про спорт, другой только про экономику). В тексте этого обоснования нет.

Мой комментарий: Метрику Gap задумывал скорее с точки зрения того, что в каждом канале присутствует собственный стиль, лексика и способность эмбеддера улавливать эту связь внутри источника может показать его чувствительность к неочевидным семантическим паттернам. Взамен можно попробовать с Precision@K оценить эмбеддеры, для каждого документа найти K соседей и посмотреть сколько из них будут принадлежать к каналу исходного документа

1.3 Линейное масштабирование параметров HDBSCAN (Раздел 2.3.4) Использование формулы $p_{\text{slice}} = \lfloor p_{\text{full}} \cdot \frac{N_{\text{slice}}}{N_{\text{full}}} \rfloor$ — это эвристика. Плотность данных в многомерном пространстве эмбеддингов не масштабируется линейно в зависимости от объема выборки. Это работает на практике как «костыль» для предотвращения вырождения кластеров на малых срезах, но с математической точки зрения это не обосновано. На защите могут спросить, почему зависимость выбрана именно линейной.

Мой комментарий: В этом моменте я сознательно позволил себе совершить такую эвристику, упростив зависимость до линейной и по метрикам это сработало, может быть можно немного подредактировать текст и однозначно обосновать это как сработавшую эвристику

1.4 Оценка LLM-судьи на статистически незначимой выборке (Раздел 2.4.2) В тексте сказано: «Из 11 пар... LLM вынесла решение «одна тема» в одном случае и «разные темы» в десяти... Это говорит о том, что граница 0,4 отсекает действительно близкие пары». Делать вывод о корректности порогового значения для всей системы на основании проверки всего 11 пар — статистически некорректно. Это разведочный анализ (sanity check), а не доказательство.

Мой комментарий: Думаю, в этом моменте стоит смягчить самоуверенный тон выводов на основе 11 размеченных пар и добавить сноску, что калибровка этого порога требует формирование более масштабного размеченного датасета и выносится в рамки дальнейших исследований

2. Произвольные константы и нераскрытые параметры

В работе используется ряд «магических чисел», появление которых не объяснено абляционным анализом (ablation study) или отсылками к литературе:

- **Формула (2.2):** $\mathcal{L} = \text{DBC}V - 0.5 \cdot \text{NoiseRatio}$. Почему штрафной коэффициент именно 0.5? Почему DBCV и доля шума линейно сопоставимы в такой пропорции? Это явно заданный гиперпараметр целевой функции, который напрямую определил финальную модель.
- **Формула (2.4): Взвешенная сумма $0.7 \cdot \cos + 0.3 \cdot J$.** Откуда взяты веса 0,7 и 0,3? Указано лишь, что они «отражают приоритет семантического сигнала», но не показано, что было бы при соотношении 0,8/0,2 или 0,5/0,5.
- **Квантили для Ring-based sampling (Раздел 2.5): Q_{25} и Q_{60} .** Границы ядра и периферии заданы этими квантилями. Почему именно 25-й и 60-й?

Мой комментарий: Для формулы (2.2) добавить пояснение, что на практике DBCV обычно в диапазоне [0, 1] и Noise Ratio тоже [0, 1] и коэффициент 0.5 здесь говорит о том, что в процессе подбора гиперпараметров можно пожертвовать увеличением Noise Ratio на 10%, если это приведет к росту DBCV не менее чем на 0.05

Для формулы (2.4) можно сослаться на то, что веса подобраны эмпирически, но вроде бы так лучше не делать и действительно может быть стоит уделить внимание другим конфигурациям весов и провести небольшое ablation-исследование

Насчет значений квантилей в разделе 2.5, здесь ориентировался на визуальный анализ распределений косинусных расстояний от центроидов до документов, добавлю это как пояснение выбора

3. Замечания по архитектуре и логике текста

3.1 Разрыв контекста при предобработке (Раздел 2.1.3) Решение использовать `text_clean` для эмбеддингов и `text_lemm` для c-TF-IDF — технически очень грамотное. Однако при лемматизации через `rumorphy2` без снятия омонимии (POS-теггинга) возникает риск некорректного приведения к начальной форме в зависимости от контекста. Для извлечения топиков это обычно не критично, но упомянуть об ограничениях словарной лемматизации стоит.

Мой комментарий: Честно, о такой возможной проблеме раньше не слышал, на первый взгляд выглядит незначительно

3.2 Укрупнение метрик в Таблице 2.6 Указано, что типов изменений 189, хотя тем 238, так как "Merged и Split фиксируются как одна запись на группу тем". Это усложняет чтение результатов. Обычно таксономию считают со стороны среза-источника (для каждой из 238 тем A определяется ее судьба в B) либо строят граф переходов.

Мой комментарий: Согласен, идея с графом перехода тем очень пришлась о душе, планирую добавить

3.3 Падение C_V coherence В таблице 2.7 наблюдается падение когерентности с 0,810 до 0,719. В тексте это объясняется тем, что «c-TF-IDF извлекает ключевые слова из более узкого контекстного окна». Это слабое объяснение. C_V измеряется по совместной встречаемости слов (NPMI). Если

когерентность падает, значит в топ-10 слов темы стали попадать слова, которые редко встречаются вместе в реальных документах. Это прямое следствие уменьшения размера корпуса, но называть это «статистическим занижением» не совсем корректно — метрика показывает реальное ухудшение семантической связности топа слов.

Мой комментарий: Доводы выглядят правдоподобными, видимо, я неверно интерпретировал снижение метрики